Repetición espaciada sobre grafos de habilidades procedimentales

Modelo, simulador y primeros resultados

Gustavo S. de la Rosa

Octubre de 2026

Proyecto de maestría — reunión con el asesor

El problema

Lo que existe

- SM-2, FSRS, MEMORIZE (Tabibian 2019): una tarjeta = una pieza de conocimiento.
- Ítems independientes entre sí.
- Funciona muy bien para *hechos*.

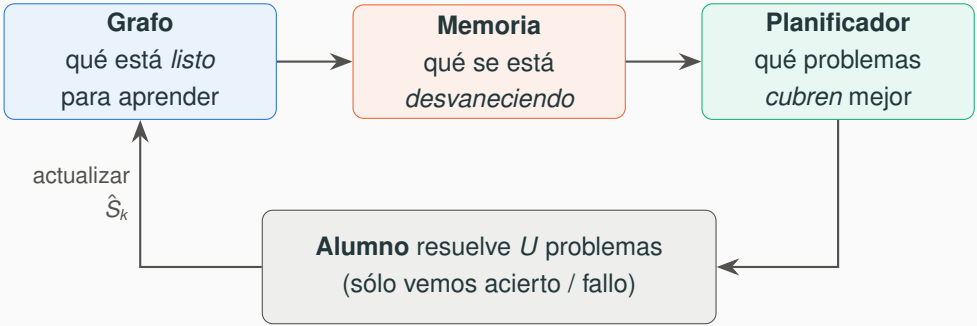
Lo que pasa en física

- Un problema de tiro parabólico usa vectores, MUA *y* composición de movimientos.
- Si falla, ¿qué falló?
- Hay un orden: sin MUA no hay tiro parabólico.
- Demasiados temas nuevos saturan la cola de repasos (Reddy 2016).

Pregunta

¿Cómo usar el modelo de olvido $R(t) = e^{-n\Delta t}$ para planificar la práctica de *habilidades* que dependen unas de otras?

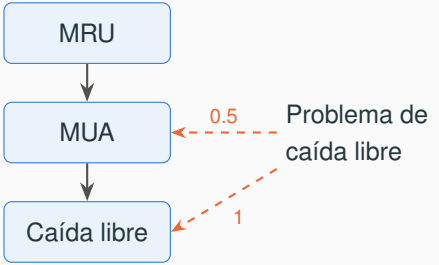
La idea en una frase



Cada sesión: calcular $\hat{R}_k$, elegir problemas, observar resultados y actualizar. Los parámetros se estiman con datos de un piloto.

El modelo

Pieza 1: grafo y matriz Q fraccional



Un problema del tema j ejercita:

$$w_{jk} = \begin{cases} 1 & k = j \\ 0.5 & k \in \mathrm{Pre}(j) \\ 0 & \text{otro} \end{cases}$$

- El tema completo y sus prerrequisitos a medias.
- Crédito implícito: practicar caída libre repasa MUA de paso.
- Los pesos w_{jk} se pueden estimar con datos.

Pieza 2: memoria y observación

Memoria (Tabibian 2019), por habilidad:

$$\hat{R}_k(t) = \exp\Big(-\frac{t - \hat{L}_k}{\hat{S}_k}\Big) = e^{-\hat{n}_k \Delta t} \qquad \hat{S}_k = \text{estabilidad (días)}$$

Observación: conjuntiva, con descuido s y adivinanza g:

$$\hat{\Pi}_j = \prod_{k \in Q(j)} \hat{R}_k^{w_{jk}}, \qquad \Pr(\text{acierto}) = (1 - s)\,\hat{\Pi}_j + g\,(1 - \hat{\Pi}_j)$$

- Sabe todo $\Rightarrow$ falla sólo por descuido ($s = 0.05$).
- No sabe algo $\Rightarrow$ acierta sólo por adivinanza ($g = 0.02$).
- Esto da una verosimilitud explícita, que es lo que permite estimar todo con datos.

Actualización: acierto, salto y culpa

Acierto: cada componente gana

$$\hat{S}_k \leftarrow \hat{S}_k \left[1 + w_{jk}\, G\,(1 - \hat{R}_k)\right]$$

- Si $\hat{R} \approx 1$, no gana nada: efecto de espaciamiento.
- La práctica masiva no puede “dominar” un tema.

Salto (Tabibian): $\hat{R}_k^{+} = \hat{R}_k + w_{jk}(1 - \hat{R}_k)$. Una sola actualización por habilidad por sesión.

Fallo: culpa bayesiana

$$b_k = \frac{1 - \hat{R}_k^{\,w_{jk}}}{1 - \hat{\Pi}_j}, \qquad \hat{S}_k \leftarrow \hat{S}_k(1 - \lambda b_k)$$

Ejemplo

$\hat{R}_{\text{caída}} = 0.64$, $\hat{R}_{\text{MUA}} = 0.79$, falla el problema:

$b_{\text{caída}} = 0.84, \quad b_{\text{MUA}} = 0.26$

El sistema concluye que el problema está en caída libre, *sin ver* qué pasó.

Pieza 3a: admisión de temas nuevos

Se introduce el tema k sólo si se cumplen dos condiciones:

1. **Está listo**: todo prerrequisito tiene $\hat{S}_p \geq S_{\text{listo}}$ y $\hat{R}_p \geq r^*$.
   Es el *outer fringe* de la teoría de espacios de conocimiento (Doignon y Falmagne 1985).
2. **Cabe**: la carga de mantenimiento no excede una fracción ρ del presupuesto U:

$$\mathcal{L} = \sum_{k} \min\left(1, \frac{7/5}{\hat{S}_k \ln(1/r^*)}\right), \qquad \mathcal{L} + 1 \leq \rho\, U$$

Qué gana

Convierte la observación de saturación de Reddy et al. (2016) en un invariante: si el modelo es correcto, la carga esperada nunca rebasa ρU.

Pieza 3b: elegir los problemas de la sesión

Vencidas: $D = \{k : \hat{R}_k < r^*\}$, con prioridad $\pi_k = 1 - \hat{R}_k$ (la forma $u^* \propto 1 - m$ de Tabibian).

$$V(A) = \sum_{k \in D} \pi_k \Big[1 - \prod_{j \in A} (1 - w_{jk})\Big] \qquad \text{(cobertura de lo vencido)}$$

Proposición

V es monótona y submodular $\Rightarrow$ el algoritmo voraz alcanza al menos $(1 - 1/e) \approx 63\%$ del óptimo (Nemhauser et al. 1978).

- Prefiere un problema integrador que cubra varias habilidades vencidas a la vez.
- Descarta problemas con componentes muy olvidados ($\hat{R} < 0.6$).
- Ojo: la garantía es sobre V, no sobre el aprendizaje.

Estimación con un piloto

Parámetros libres: $\phi = (\hat{S}_0,\ G,\ \lambda)$.

$$\mathrm{NLL}(\phi) = -\sum_i \sum_n \Big[y_{in} \ln \hat{P}_{in}(\phi) + (1 - y_{in}) \ln\big(1 - \hat{P}_{in}(\phi)\big) \Big]$$

- Se reproduce la historia de cada alumno como un filtro: predecir, observar, actualizar.
- Nelder–Mead sobre $(\ln \hat{S}_0,\ \ln G,\ \operatorname{logit} \lambda)$.
- El mismo flujo sirve con datos reales; ahí entraría un modelo jerárquico con efecto por alumno.

Ejemplo: en el grafo de subtemas (escenario A) se estimó $\hat{S}_0 = 8.2$, $G = 7.2$, $\lambda = 0.13$, con 54 000 intentos de 100 alumnos simulados.

¿Cómo evaluarlo sin datos?

Simulador con verdad mal especificada

	Verdad (alumno simulado)	**Modelo** (planificador)
Olvido	ley de potencia (FSRS)	exponencial
Ganancia	$\gamma S^{-b}(e^{c(1-R)}-1)$	$G(1-\hat{R})$
Fallo	lapso en lo que *de verdad* falló (oculto)	culpa bayesiana
Bases débiles	daño leve (A) o persistente (B)	sólo la compuerta
Alumnos	heterogéneos, $\theta \sim N(0, 0.35^2)$	iguales

- Si el planificador decidiera con el mismo modelo que genera los datos, ganaría por construcción.
- Es la misma situación que en un aula: el modelo aproxima algo que no se observa.

Diseño de la simulación

Políticas

- Propuesto ($r^* = 0.7$) y con $r^* = 0.9$; 4 ablaciones
- Anki SM-2 (una tarjeta por tema)
- Libro bloqueado y libro con repaso acumulativo

Métrica

- P(resolver un problema nuevo) a 30 días del fin, sin práctica, promediada sobre *todo* el grafo
- 300 alumnos, comparación pareada

Grafos (tu grafo de mecánica)

- **15 unidades**, 26 aristas
  $U = 6$ problemas/sesión
- **168 subtemas**, 279 dependencias anotadas a mano
  $U = 10$, hasta 3 temas nuevos/sesión
- **Control**: los mismos subtemas como cadenas lineales

Curso: 12 semanas, 5 sesiones/semana.

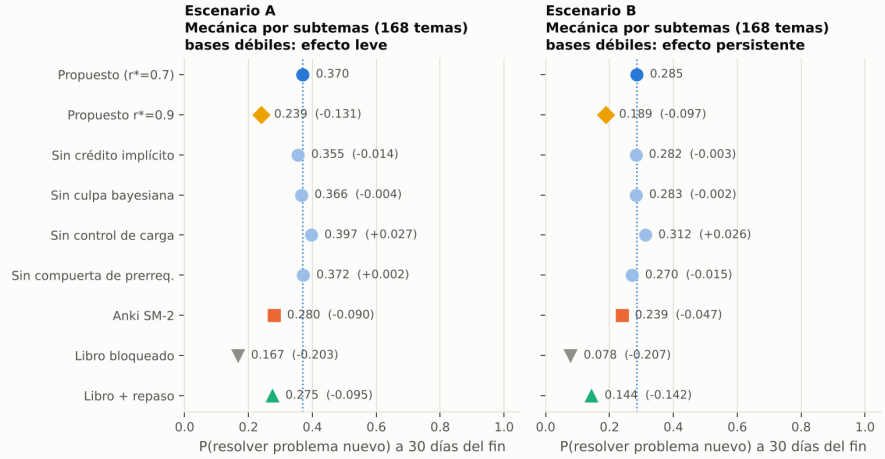
Resultados

Resultado 1: con 15 unidades, no le gana a Anki

Examen diferido	A	B
Propuesto	0.743	0.714
Propuesto sin compuerta	**0.753**	**0.723**
Anki SM-2	0.749	0.722
Libro + repaso	0.628	0.605
Libro bloqueado	0.463	0.427

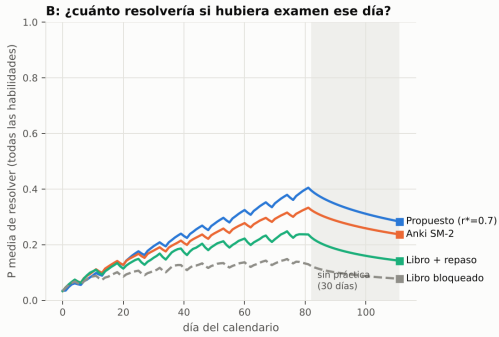
- Espaciar vale $+0.28$ frente al libro bloqueado.
- Con 4 sesiones por tema el presupuesto sobra: cualquier repaso espaciado razonable funciona igual.
- La compuerta cuesta: el grafo es profundo y retrasa la introducción de temas.
- Con $U = 4$ el propuesto sí gana (0.731 contra 0.714).

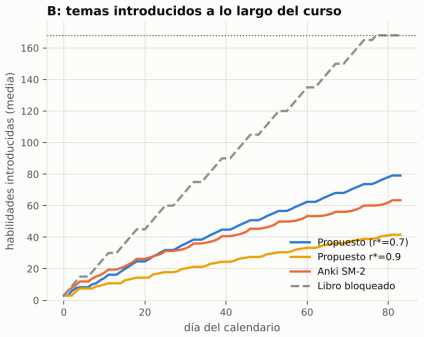
Resultado 2: con 168 subtemas, sí le gana



Propuesto frente a Anki: $+\mathbf{0.090}$ (A) y $+\mathbf{0.047}$ (B). Crédito implícito: $+0.014$ (A). Compuerta: $+0.015$ (B).

¿Por qué gana? Cobertura





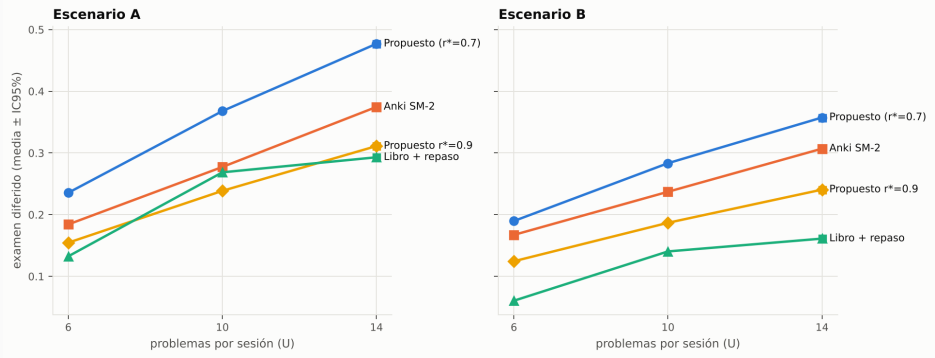
Anki se atasca con sus repasos vencidos y deja de introducir temas (63 contra 79). Con $r^* = 0.9$, el propuesto repasa tan seguido que casi no avanza.

Pero ojo: cobertura frente a retención

Escenario A	Temas	$P \geq 0.8$	P en vistos
Propuesto	106	5.5	≈ 0.58
Anki SM-2	71	11.0	≈ 0.64
Propuesto $r^* = 0.9$	56	12.6	≈ 0.68

- El propuesto gana porque cubre más temas, con una retención algo menor por tema.
- Si la meta es dominar pocos temas a fondo, la conclusión se invierte.
- r^* no es un detalle técnico: es una decisión pedagógica sobre esta frontera.

La ventaja se mantiene con distintos presupuestos



La estructura del grafo importa

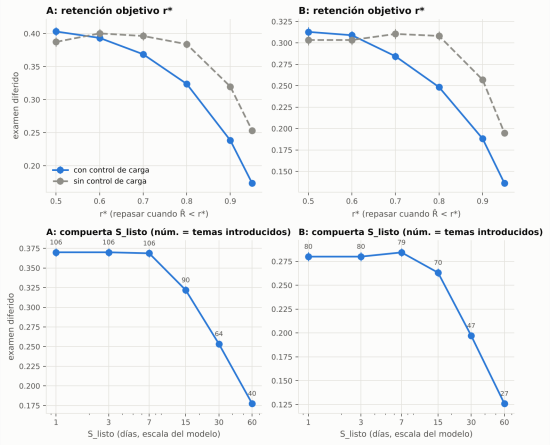
Escenario B	Dependencias	Lineal
Propuesto	0.285	0.124
Anki SM-2	0.239	0.238
Sin compuerta	0.270	0.234
Temas (propuesto)	79	28

- En cadenas lineales hay 103 niveles y sólo un tema admisible a la vez.
- La compuerta serializa el curso y el propuesto se hunde; Anki ignora el grafo y no sufre.

Moraleja

Un grafo con dependencias falsas castiga justo al sistema que lo respeta. La fidelidad del grafo importa tanto como la fórmula de repaso.

Sensibilidad: retención objetivo y compuerta



Discusión

Limitaciones

- **La verdad es un modelo**: dice qué *podría* importar, no cuánto se gana en un aula.
- $r^* = 0.7$ **se eligió después** de un barrido preliminar; hay que fijarlo sin usar la verdad.
- **La métrica premia la cobertura**; un r^* bajo implica más fallos y posibles costos de motivación.
- **Grafo de subtemas**: las 279 dependencias son un borrador sin validación docente.
- **Simplificaciones**: culpa sin s ni g, $\hat{S}_0$ común, sin efectos por alumno; $\hat{\lambda} \approx 0$ en un escenario (identificabilidad).
- **No se modela** intercalado, fatiga, ejemplos resueltos ni variación entre instancias.

Próximos pasos

1. Culpa completa con s y g; estimar s, g y w_{jk}.
2. Validar el grafo de subtemas con docentes.
3. Piloto real $\rightarrow$ modelo jerárquico; comparar olvido exponencial y de potencia.
4. Criterio explícito para r^* (cobertura frente a dominio).
5. **Experimento**: intra-sujeto contrabalanceado (Lindsey et al. 2014), propuesto frente a FSRS/SM-2, tiempo igualado, prueba a 30 días.
   $n = 7.85/d_z^2$: 32 alumnos para $d_z = 0.5$; 88 para $d_z = 0.3$.

Preguntas para discutir

1. **Granularidad**: ¿subtemas, o habilidades todavía más finas?
2. **Objetivo pedagógico**: ¿maximizar cobertura o dominio? Eso fija r^*.
3. **Validación del grafo**: ¿con qué docentes o con qué datos?
4. **Alcance de la tesis**: ¿modelo + simulación + piloto, o hasta el experimento en aula?
5. **Posicionamiento**: frente a Choffin et al. (2021) y Math Academy, ¿la contribución es el modelo formal, la evaluación o ambas?

Respaldo

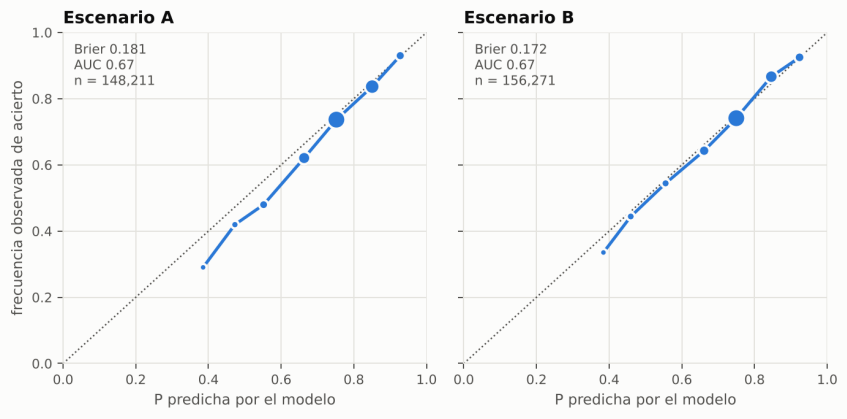
Respaldo: parámetros de la verdad simulada

	Valor	Significado
S_0	0.6 d	estabilidad inicial
δ	0.15	penalización por profundidad
a	$\ln 4$	escala de ganancia
b	0.15	rendimientos decrecientes
c	2	efecto de espaciamiento

	Valor	Significado
ℓ	0.6	pérdida en un lapso
κ	4 d	consolidación de bases
s, g	0.05, 0.02	descuido, adivinanza
σ_θ	0.35	heterogeneidad
$S_{\min}$	0.2 d	piso

Olvido: $R = (1 + \frac{19}{81}\Delta t/S)^{-1/2}$, de modo que $R(S) = 0.9$.

Respaldo: calibración del modelo



AUC ≈ 0.67. El modelo sobreestima en el rango medio, como era de esperar si la verdad olvida con ley de potencia.